

הגשת מטלה בלמידת מכונה: סיווג תמונות (Rock-Paper-Scissors)

פרטי הסטודנטים:

- ניר י. - 1498
- דניאל צ. - 6313
- יהונתן י. - 9248

חלק 1 – הקדמה וטעינת הנתונים

שימוש בפרומפטים ועזרים (AI):

במהלך העבודה נעזרנו ב-Gemini AI למטרות הבאות:

1. ארגון קוד ה-Pipeline המלא לעבודה ב-Google Colab מול נתוני ה-Drive.
2. פיתוח פונקציית Feature Engineering מתקדמת הכוללת הפרדת רקע באמצעות Otsu Thresholding, חיתוך מדויק במסגרת תוחמת (Bounding Box), ושמירה על פרופורציות (Aspect-Ratio Padding) למניעת עיוותים גיאומטריים.
3. כתיבת מנגנון Grid-Search בשילוב 5-Fold Cross Validation להערכת שילובי ההיפר-פרמטרים של אלגוריתם ה-KNN והצגת התוצאות ב-DataFrame, כנדרש בסעיף ההרחבות.

הסבר על בעיית הלמידה וה-Dataset:

הבעיה הנחקרת היא **סיווג מרובה מחלקות (Multi-class Classification)** של תמונות ידיים המדגימות את משחק האבן-נייר-מספריים (Computer Vision). מטרת המערכת היא לזהות את תנועת היד מתוך תמונה גולמית ולסווג אותה לאחת משלוש קטגוריות: Rock, Paper, Scissors. הנתונים מחולקים מראש בתיקיות ה-Drive ל-Train ול-Test, ובהתאם להנחיות המטלה - טענו אותם באופן מופרד ולא **חילקנו את ה-Datasets הללו שוב**.

קוד: טעינת הנתונים וערבוב (Shuffling)

```
from google.colab import drive
import os
import cv2
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.metrics import f1_score
from sklearn.neighbors import KNeighborsClassifier
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import GridSearchCV, KFold
from sklearn.utils import shuffle

# =====
# PART 1: Mount Drive & Set Correct Paths
# =====
drive.mount('/content/drive')

base_dir = '/content/drive/MyDrive/ML_Project/Rock_Paper_Scissors/Rock-Paper-Scissors'
train_dir = os.path.join(base_dir, 'train')
test_dir = os.path.join(base_dir, 'test')

categories = ['rock', 'paper', 'scissors']
IMG_SIZE = 48

# =====
# PART 2: Load Dataset & Shuffle
# =====
def load_data(directory):
    """Load images and labels from a given directory."""
    X, y = [], []
    for category in categories:
        folder_path = os.path.join(directory, category)
        if not os.path.exists(folder_path):
            continue

        label = categories.index(category)
        for img_name in os.listdir(folder_path):
            img_path = os.path.join(folder_path, img_name)
            img = cv2.imread(img_path)
            if img is not None:
                # Convert to RGB for proper plotting
```

```
X.append(cv2.cvtColor(img, cv2.COLOR_BGR2RGB))
y.append(label)

# Shuffle indices to prevent sequence bias
indices = np.arange(len(X))
np.random.shuffle(indices)
return np.array([X[i] for i in indices]), np.array([y[i] for i in indices])

print("Loading Train and Test datasets separately...")
X_train_raw, y_train = load_data(train_dir)
X_test_raw, y_test = load_data(test_dir)
print(f"Loaded {len(X_train_raw)} Train images and {len(X_test_raw)} Test images.")
```

חלק 2 – Feature Engineering

- אלגוריתם KNN מתבסס על מרחק מתמטי בין פיקסלים, ולכן רגיש לרעשי רקע ולעיוותים גיאומטריים. פיתחנו עיבוד מוקדם ייעודי (Preprocessing) וייצרנו 5 דוגמאות ויזואליות מה-Dataset כדי להציג את התהליך:
1. **המרת סף אוטומטית (Otsu Thresholding):** הפרדה חדה בין היד לבין הרקע הלבן.
 2. **חיתוך קופסה תוחמת (Bounding Box Crop):** הסרת כל השטחים הלבנים המיותרים מסביב ליד.
 3. **שמירה על פרופורציות (Aspect-Ratio Padding):** הוספת שוליים שחורים להפיכת הצורה לריבוע מושלם *לפני* ההקטנה, כדי למנוע מ"נייר" (צורה ארוכה) להיראות כמו "אבן" עקב מעיכה גיאומטרית.

```

# =====
# PART 3: Feature Engineering (Aspect-Ratio Preserving Crop)
# =====
def get_hand_mask_and_crop(img_rgb):
    """
    Applies Grayscale -> Gaussian Blur -> Otsu Thresholding -> Aspect-Ratio Preserving Crop.
    Padding the cropped bounding box to a perfect square before resizing prevents
    shape distortion (e.g., stopping 'Paper' from squashing and looking like 'Rock').
    """
    gray = cv2.cvtColor(img_rgb, cv2.COLOR_RGB2GRAY)
    blur = cv2.GaussianBlur(gray, (5, 5), 0)

    # Otsu thresholding separates the hand from the white background
    _, thresh = cv2.threshold(blur, 0, 255, cv2.THRESH_BINARY_INV + cv2.THRESH_OTSU)

    # Find bounding box to crop out empty background
    points = cv2.findNonZero(thresh)
    if points is not None:
        x, y, w, h = cv2.boundingRect(points)
        cropped_hand = thresh[y:y+h, x:x+w]

        # CRITICAL FIX: Pad the image to a square BEFORE resizing to preserve aspect ratio
        max_dim = max(w, h)
        pad_top = (max_dim - h) // 2
        pad_bottom = max_dim - h - pad_top
        pad_left = (max_dim - w) // 2
        pad_right = max_dim - w - pad_left

        # Add black padding (value=0) around the hand
        square_hand = cv2.copyMakeBorder(cropped_hand, pad_top, pad_bottom, pad_left, pad_right, cv2.BORDER_CONSTANT, 0)
    else:
        square_hand = thresh

    # Resize to the final grid
    resized = cv2.resize(square_hand, (IMG_SIZE, IMG_SIZE))
    return resized

print("\n--- Part 2: Feature Engineering (Smart Square Crop) ---")

X_train_masks = np.array([get_hand_mask_and_crop(img) for img in X_train_raw])
X_test_masks = np.array([get_hand_mask_and_crop(img) for img in X_test_raw])

# -----

```

```
# Feature Engineering Visualization: 1 Row Originals, 1 Row Masks (Showing 5 examples as required)
# -----
num_examples = 5
fig, axes = plt.subplots(2, num_examples, figsize=(15, 6))

for i in range(num_examples):
    # Top row: Original images
    axes[0, i].imshow(X_train_raw[i])
    axes[0, i].set_title(f"Original: {categories[y_train[i]].capitalize()}")
    axes[0, i].axis('off')

    # Bottom row: Processed masks
    axes[1, i].imshow(X_train_masks[i], cmap='gray')
    axes[1, i].set_title("Square Cropped Mask")
    axes[1, i].axis('off')

plt.suptitle("Feature Engineering: Original vs. Aspect-Ratio Preserving Crop", fontsize=16, fontweight='bold')
plt.tight_layout()
plt.show()

# Flatten and Normalize for the KNN Algorithm
X_train_features = X_train_masks.reshape(len(X_train_masks), -1)
X_test_features = X_test_masks.reshape(len(X_test_masks), -1)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train_features)
X_test_scaled = scaler.transform(X_test_features)
```

חלק 3 ו-4 – אלגוריתם הלמידה, חיפוש פרמטרים (Grid-Search) ואימון (בונוס 6.א)

בחרנו באלגוריתם **KNN (K-Nearest Neighbors)**. כחלק מסעיף ההרחבות (6.א), ביצענו סריקת היפר-פרמטרים מקיפה במכפלה קרטזית באמצעות **Grid-Search**. בדקנו מספרי שכנים שונים, שיטות מדידת מרחק (Euclidean לעומת Manhattan) ושיטות משקולות. הערכת הביצועים נוהלה תחת מעטפת של **Fold Cross Validation-5**. התוצאות הממוצעות מוצגות בטבלת DataFrame, והפרמוטציה הטובה ביותר נבחרה אוטומטית לאימון מחדש של ה-Trainset כולו.

```

# =====
# PART 4: Algorithm Implementation, Grid Search & Training
# =====
print("\n--- Part 3 & 4: Hyperparameter Tuning (Grid Search & 5-Fold CV) ---")

# Define the hyperparameter grid to search (Cartesian product)
param_grid = {
    'n_neighbors': [5, 11, 15, 19, 25],
    'weights': ['uniform', 'distance'],
    'metric': ['euclidean', 'manhattan']
}

knn = KNeighborsClassifier()

# Configure 5-Fold Cross Validation
cv_strategy = KFold(n_splits=5, shuffle=True, random_state=42)

# Initialize GridSearchCV using Macro F1-Score as the scoring metric
grid_search = GridSearchCV(
    estimator=knn,
    param_grid=param_grid,
    cv=cv_strategy,
    scoring='f1_macro',
    n_jobs=-1
)

# Execute Grid Search
grid_search.fit(X_train_scaled, y_train)

# -----
# Presenting Results in a DataFrame (As requested in Bonus 6.a)
# -----
results_df = pd.DataFrame(grid_search.cv_results_)
# Filter and rename relevant columns for display
display_cols = ['param_n_neighbors', 'param_weights', 'param_metric', 'mean_test_score']
results_df = results_df[display_cols].sort_values(by='mean_test_score', ascending=False)
results_df.columns = ['K (Neighbors)', 'Weights', 'Distance Metric', 'Mean CV Macro F1']

print("\n>>> Top 5 Hyperparameter Permutations (Cross-Validation Results DataFrame):")
print("=====")
print(results_df.head(5).to_string(index=False))
print("=====")

```

```
# -----  
# Presenting the Best Permutation  
# -----  
print(f"\n>>> BEST PERMUTATION FOUND:")  
print(f"Parameters: {grid_search.best_params_}")  
print(f"Best Macro Average F1-Score (Cross-Validation): {grid_search.best_score_:.4f}")  
  
# The GridSearchCV automatically refits the best estimator on the entire training set.  
# We extract it here for clarity.  
best_knn_model = grid_search.best_estimator_  
print("\nTraining final model on the entire trainset using the best parameters... Completed.")
```

חלק 5 – חיזוי ושערוך איכות המודל

המודל הסופי הופעל על סט הבדיקה (Test Set) שעבר בדיוק את אותו Preprocessing. מכיוון שמדובר בבעיית סיווג Multi-Class ללא מחלקה מרכזית אחת, איכות המודל נמדדת באמצעות מדד ה-**Macro Average F1-Score** בהתאם לדרישות המטלה. אנו מציגים מטה ויזואליזציה של 25 החיזויים הראשונים על סט הבדיקה.

```

# =====
# PART 5: Prediction and Evaluation on Test Set
# =====
print("\n--- Part 5: Prediction and Model Quality Evaluation ---")

if len(X_test_scaled) > 0:
    # Predict using the BEST model found by Grid-Search
    y_pred = best_knn_model.predict(X_test_scaled)

    # -----
    # Classification Visualization: 5 Rows x 5 Columns (25 Images)
    # -----
    rows, cols = 5, 5
    fig, axes = plt.subplots(rows, cols, figsize=(18, 18))

    for row_idx in range(rows):
        for col_idx in range(cols):
            img_idx = row_idx * cols + col_idx

            if img_idx < len(X_test_raw):
                ax = axes[row_idx, col_idx]
                ax.imshow(X_test_raw[img_idx])

                actual_label = categories[y_test[img_idx]].capitalize()
                pred_label = categories[y_pred[img_idx]].capitalize()

                text_color = 'green' if y_test[img_idx] == y_pred[img_idx] else 'red'
                title_text = f"Actual: {actual_label}\nPred: {pred_label}"

                ax.set_title(title_text, color=text_color, fontweight='bold', fontsize=12)
                ax.axis('off')

            # Add a dashed line separator between rows (except after the last row)
            if row_idx < rows - 1:
                ax_mid = axes[row_idx, 2] # Use the middle column axis as reference
                # Draw a line spanning across all columns (-2.5 to 3.5 covers 5 columns)
                ax_mid.plot([-2.5, 3.5], [-0.3, -0.3], color='gray', linestyle='--', linewidth=2, transp

plt.suptitle("25 Diverse Predictions vs Actual (Test Set)", fontsize=22, fontweight='bold')

# Adjust layout to fit the main title
plt.tight_layout(rect=[0, 0, 1, 0.96])
# Add significant vertical space between rows

```

```
fig.subplots_adjust(hspace=0.8)

plt.show()

# Calculate Macro Average F1-Score
macro_f1 = f1_score(y_test, y_pred, average='macro')
print(f"\n=====")
print(f"Final Model Quality on Test Set (Macro Average F1-Score): {macro_f1:.4f}")
print(f"=====")
else:
    print("Test set is empty. Cannot perform evaluation.")
```